（一）线性回归基础

1. **定义**：线性回归是一种**监督学习算法**，用于建模自变量（特征）与因变量（目标值）之间的**线性关系**。
2. **核心假设**：
   - 自变量与因变量之间存在线性相关关系；
   - 误差项服从均值为 0、方差恒定的正态分布；
   - 误差项之间相互独立。
3. **模型形式**：
   - 单变量线性回归（1 个自变量）：

     $y = wx + b$

     其中，x 是自变量，y 是因变量，w（斜率）和 b（截距）是待求参数。
   - 多变量线性回归（n 个自变量）：

     $y = w_1x_1 + w_2x_2 + ... + w_nx_n + b$

     或矩阵形式：$\boldsymbol{y} = \boldsymbol{X}\boldsymbol{w} + \boldsymbol{\varepsilon}$（$\boldsymbol{\varepsilon}$ 为误差项）。

（二）最小二乘法（Least Squares Method）

1. **核心思想**：通过最小化**误差的平方和**来求解模型参数（w 和 b），即找到使观测值与模型预测值的偏差平方和最小的参数组合。
2. **误差定义**：对于单变量线性回归，第 i 个样本的误差为 $\varepsilon_i = y_i - \hat{y}_i$（$y_i$ 是真实值，$\hat{y}_i = wx_i + b$ 是预测值）。
3. **目标函数**（最小化平方误差和）：

   $J(w,b) = \sum_{i=1}^{m}(y_i - (wx_i + b))^2$

   其中 m 是样本数量。

（三）参数求解（单变量线性回归）

通过**求导令梯度为 0**（解析解），直接得到最优参数 w 和 b：

1. 先定义中间变量：
   - 样本均值：$\bar{x} = \frac{1}{m}\sum_{i=1}^{m} x_i$，$\bar{y} = \frac{1}{m}\sum_{i=1}^{m} y_i$
   - 分子（协方差）：$Cov(x,y) = \sum_{i=1}^{m}(x_i - \bar{x})(y_i - \bar{y})$
   - 分母（x 的方差）：$Var(x) = \sum_{i=1}^{m}(x_i - \bar{x})^2$
2. 最优参数：
   - 斜率 $w = \frac{Cov(x,y)}{Var(x)} = \frac{\sum_{i=1}^{m}(x_i-\bar{x})(y_i-\bar{y})}{\sum_{i=1}^{m}(x_i-\bar{x})^2}$
   - 截距 $b = \bar{y} - w\bar{x}$

（四）模型评估指标

1. **均方误差（MSE）**：$MSE = \frac{1}{m}\sum_{i=1}^{m}(y_i - \hat{y}_i)^2$（反映误差的平均平方大小）；

2. **决定系数（R^2）**：$R^2 = 1 - \frac{\sum_{i=1}^{m}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{m}(y_i - \bar{y})^2}$（衡量模型拟合优度，$R^2$ 越接近 1，拟合效果越好）。

某商店统计了过去 6 个月的广告投入（x，单位：千元）与月销售额（y，单位：万元），数据如下表。请用最小二乘法建立线性回归模型 $y = wx + b$，并预测当广告投入为 10 千元时的月销售额。

月份	广告投入 x（千元）	月销售额 y（万元）
1	2	3
2	3	4
3	5	6
4	6	7
5	8	9
6	9	10

步骤 1：计算样本均值 $\bar{x}$ 和 $\bar{y}$

- 样本数量 $m = 6$
- $\bar{x} = \frac{2+3+5+6+8+9}{6} = \frac{33}{6} = 5.5$（千元）
- $\bar{y} = \frac{3+4+6+7+9+10}{6} = \frac{39}{6} = 6.5$（万元）

步骤 2：计算分子 $Cov(x, y)$ 和分母 $Var(x)$

- 分子 $Cov(x, y) = 37.5$
- 分母 $Var(x) = 37.5$

步骤 3：求解参数 w 和 b

- 斜率 $w = \frac{Cov(x,y)}{Var(x)} = \frac{37.5}{37.5} = 1$
- 截距 $b = \bar{y} - w\bar{x} = 6.5 - 1 \times 5.5 = 1$

步骤 4：得到线性回归模型

$\hat{y} = x + 1$（即广告投入每增加 1 千元，月销售额增加 1 万元）。

步骤 5：预测广告投入为 10 千元时的销售额

将 $x = 10$ 代入模型：

$\hat{y} = 10 + 1 = 11$（万元）。

步骤 6：模型评估（计算 R^2）

- 总平方和 $SST = \sum(y_i - \bar{y})^2 = (-3.5)^2 + (-2.5)^2 + (-0.5)^2 + 0.5^2 + 2.5^2 + 3.5^2 = 37.5$
- 残差平方和 $SSE = \sum(y_i - \hat{y}_i)^2$（因模型完全拟合数据，$SSE = 0$）
- $R^2 = 1 - \frac{SSE}{SST} = 1 - 0 = 1$（拟合效果完美）。

题目

假设某房屋的售价（y，万元）与面积（x_1，㎡）、房龄（x_2，年）相关，样本数据如下。用最小二乘法求解回归模型 $y = w_1x_1 + w_2x_2 + b$。

样本	x_1（㎡）	x_2（年）	y（万元）
1	100	5	80
2	120	3	95
3	80	8	65
4	150	2	120
5	90	6	70

核心思路（矩阵形式求解）

多变量线性回归的参数解析解为 $\boldsymbol{w} = (\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T\boldsymbol{y}$，其中：

- 设计矩阵 $\boldsymbol{X} = \begin{bmatrix} 1 & 100 & 5 \\ 1 & 120 & 3 \\ 1 & 80 & 8 \\ 1 & 150 & 2 \\ 1 & 90 & 6 \end{bmatrix}$ （第一列为 1，对应截距 b）
- 目标向量 $\boldsymbol{y} = \begin{bmatrix} 80 \\ 95 \\ 65 \\ 120 \\ 70 \end{bmatrix}$
- 参数向量 $\boldsymbol{w} = \begin{bmatrix} b \\ w_1 \\ w_2 \end{bmatrix}$

计算结果（通过矩阵运算）

$\boldsymbol{w} = \begin{bmatrix} -10.2 \\ 0.8 \\ -1.5 \end{bmatrix}$，即回归模型为：

$$\hat{y} = 0.8x_1 - 1.5x_2 - 10.2$$

解读

- 面积每增加 1㎡，售价增加 0.8 万元；
- 房龄每增加 1 年，售价减少 1.5 万元；
- 当面积为 110㎡、房龄为 4 年时，预测售价为 $\hat{y} = 0.8 \times 110 - 1.5 \times 4 - 10.2 = 79.8$ 万元。